


AUTOENCODERS

(AUTO CODIFICADORES)


Autoencoding (Auto codificación)

- Es un algoritmo de compresión de datos en el que las funciones de compresión y descompresión son
 - ▣ Específicas de los datos
 - ▣ Con pérdida
 - ▣ Aprendidas automáticamente




Autoencoder

- Entrenamiento
 - ▣ La entrada y la salida son iguales.
 - ▣ Entrenamiento **NO supervisado** aunque usa mecanismos supervisados.
- Tres modelos: encoder, decoder, autoencoder=decoder(encoder(x))



Red Codificadora

- Genera una representación vectorial de tamaño K
 - ▣ $K \ll$ tamaño original de la imagen
- La nueva representación comprime la imagen
- Es una red neuronal feedforward o convolucional



Red Decodificadora

- Recibe la imagen codificada y genera una imagen de igual tamaño que la imagen de entrada.
- Descomprime la imagen.
- Es una red neuronal feedforward o convolucional





Imagen codificada

- Es un vector numérico de tamaño K (vector latente)
- El valor de K es arbitrario
 - ▣ A mayor valor de K mejora la representación y se reduce la compresión.

Su valor se infiere



Ejemplo

- Construiremos un autoencoder para comprimir los dígitos de MNIST



- Tanto el codificador como el decodificador estarán formados por una única capa densa.

Carga de datos

```
from tensorflow.keras.layers import Dense, Input
from tensorflow.keras.models import Model
from tensorflow.keras.datasets import mnist
```

Nombre ▲	Tipo	Tamaño
input_dim	int	1
x_test	Array of uint8	(10000, 28, 28)
x_train	Array of uint8	(60000, 28, 28)

```
(x_train, _), (x_test, _) = mnist.load_data()
```

```
input_dim = 28*28
```

```
x_train = np.reshape(x_train, [-1, input_dim])/255.0
```

```
x_test = np.reshape(x_test, [-1, input_dim])/255.0
```

```
print(x_train.shape, x_test.shape, input_dim)
```

Nombre ▲	Tipo	Tamaño
input_dim	int	1
x_test	Array of floa...	(10000, 784)
x_train	Array of floa...	(60000, 784)

Modelos Encoder y Decoder

```

encoding_dim = 32  #factor de compresion 24.5, si entrada de 28x28=784
##----- ENCODER -----
encoder_input = Input(shape=(input_dim,), name='encoder_input')
code = Dense(encoding_dim, activation='relu',
              name='latent_vector')(encoder_input)
encoder = Model(encoder_input, code, name='encoder')

```

Model: "encoder"

Layer (type)	Output Shape	Param #
encoder_input (InputLayer)	[(None, 784)]	0
latent_vector (Dense)	(None, 32)	25120
Total params: 25,120		

Modelos Encoder y Decoder

```
encoding_dim = 32  #factor de compresion 24.5, si entrada de 28x28=784
##----- ENCODER -----
encoder_input = Input(shape=(input_dim,), name='encoder_input')
code = Dense(encoding_dim, activation='relu',
              name='latent_vector')(encoder_input)
encoder = Model(encoder_input, code, name='encoder')
##----- DECODER -----
latent_input = Input(shape=(encoding_dim,), name='decoder_input')
decoded_image = Dense(input_dim, activation="sigmoid",
                      name='decoder_output')(latent_input)
decoder = Model(latent_input, decoded_image, name='decoder')
```

Modelos Encoder y Decoder

Model: "decoder"

Layer (type)	Output Shape	Param #
decoder_input (InputLayer)	[(None, 32)]	0
decoder_output (Dense)	(None, 784)	25872
Total params: 25,872		

##----- DECODER -----

```
latent_input = Input(shape=(encoding_dim,), name='decoder_input')
decoded_image = Dense(input_dim, activation="sigmoid",
                      name='decoder_output')(latent_input)
decoder = Model(latent_input, decoded_image, name='decoder')
```

Modelo Autoencoder

```
autoencoder = Model(encoder_input, decoder(encoder_input)),  
                    name='autoencoder')  
autoencoder.compile(loss='binary_crossentropy', optimizer='adam')
```

Model: "autoencoder"

Layer (type)	Output Shape	Param #
=====		
encoder_input (InputLayer)	[(None, 784)]	0

encoder (Functional)	(None, 32)	25120

decoder (Functional)	(None, 784)	25872
=====		
Total params: 50,992		

Entrenamiento y uso

```
batch_size = 128
autoencoder.fit(x_train, x_train, validation_data=(x_test, x_test),
                epochs=50, batch_size=batch_size)
```

```
# Predicción del Autoencoder
```

```
x_decoded = autoencoder.predict(x_test)
```

```
# Codifica y decodifica algunos dígitos
```

```
encoded_imgs = encoder.predict(x_test)
```

```
decoded_imgs = decoder.predict(encoded_imgs)
```

Después de 50 épocas, el error en entrenamiento y testeo es de aprox. 0.009



Deep Autoencoder

```
input_img = layers.Input(shape=(784,))  
encoded = layers.Dense(128, activation='relu')(input_img)  
encoded = layers.Dense(64, activation='relu')(encoded)  
encoded = layers.Dense(32, activation='relu')(encoded)
```

```
decoded = layers.Dense(64, activation='relu')(encoded)  
decoded = layers.Dense(128, activation='relu')(decoded)  
decoded = layers.Dense(784, activation='sigmoid')(decoded)
```

```
autoencoder = Model(input_img, decoded)
```

Total params: 222,384

Después de 100 épocas, el error en entrenamiento y testeo es de aprox. 0.006

Autoencoder convolucional

```
input_img = layers.Input(shape=(28, 28, 1))
x = layers.Conv2D(16, (3, 3), activation='relu', padding='same')(input_img)
x = layers.MaxPooling2D((2, 2), padding='same')(x) # -> (14, 14, 16)
x = layers.Conv2D(8, (3, 3), activation='relu', padding='same')(x)
x = layers.MaxPooling2D((2, 2), padding='same')(x) # -> (7, 7, 8)
x = layers.Conv2D(8, (3, 3), activation='relu', padding='same')(x)
encoded = layers.MaxPooling2D((2, 2), padding='same')(x) # -> (4, 4, 8)

#--en este punto la representación es (4, 4, 8) i.e. 128-dimensional
x = layers.Conv2D(8, (3, 3), activation='relu', padding='same')(encoded)
x = layers.UpSampling2D((2, 2))(x)
x = layers.Conv2D(8, (3, 3), activation='relu', padding='same')(x)
x = layers.UpSampling2D((2, 2))(x)
x = layers.Conv2D(16, (3, 3), activation='relu')(x)
x = layers.UpSampling2D((2, 2))(x)
decoded = layers.Conv2D(1, (3, 3), activation='sigmoid', padding='same')(x)

# --- Modelo final ---
autoencoder = Model(input_img, decoded)

autoencoder.compile(optimizer='adam', loss='binary_crossentropy')


print(autoencoder.summary())
```

Layer (type)	Output Shape	Param #
input_layer_1 (InputLayer)	(None, 28, 28, 1)	0
conv2d_7 (Conv2D)	(None, 28, 28, 16)	160
max_pooling2d_3 (MaxPooling2D)	(None, 14, 14, 16)	0
conv2d_8 (Conv2D)	(None, 14, 14, 8)	1,160
max_pooling2d_4 (MaxPooling2D)	(None, 7, 7, 8)	0
conv2d_9 (Conv2D)	(None, 7, 7, 8)	584
max_pooling2d_5 (MaxPooling2D)	(None, 4, 4, 8)	0
conv2d_10 (Conv2D)	(None, 4, 4, 8)	584
up_sampling2d_3 (UpSampling2D)	(None, 8, 8, 8)	0
conv2d_11 (Conv2D)	(None, 8, 8, 8)	584
up_sampling2d_4 (UpSampling2D)	(None, 16, 16, 8)	0
conv2d_12 (Conv2D)	(None, 14, 14, 16)	1,168
up_sampling2d_5 (UpSampling2D)	(None, 28, 28, 16)	0
conv2d_13 (Conv2D)	(None, 28, 28, 1)	145

Total params: 4,385 (17.13 KB)

Autoencoder convolucional

- Resultado del entrenamiento con 10 épocas



Autoencoder convolucional

- En lugar de UpSampling se puede usar **Conv2DTranspose**

```
input_img = layers.Input(shape=(32, 32, 1))

# --- Encoder ---
x = layers.Conv2D(16, (3, 3), activation='relu', padding='same')(input_img)
x = layers.MaxPooling2D((2, 2), padding='same')(x) # -> (16, 16, 16)
x = layers.Conv2D(8, (3, 3), activation='relu', padding='same')(x)
x = layers.MaxPooling2D((2, 2), padding='same')(x) # -> (8, 8, 8)
x = layers.Conv2D(8, (3, 3), activation='relu', padding='same')(x)
encoded = layers.MaxPooling2D((2, 2), padding='same')(x) # -> (4, 4, 8)

# --- Decoder usando Conv2DTranspose ---
x = layers.Conv2DTranspose(8, (3, 3), strides=2, activation='relu', padding='same')(encoded)
x = layers.Conv2DTranspose(8, (3, 3), strides=2, activation='relu', padding='same')(x)
x = layers.Conv2DTranspose(16, (3, 3), strides=2, activation='relu', padding='same')(x)
decoded = layers.Conv2D(1, (3, 3), activation='sigmoid', padding='same')(x)



# --- Modelo final ---
autoencoder = Model(input_img, decoded)

autoencoder.compile(optimizer='adam', loss='binary_crossentropy')

print(autoencoder.summary())
```

Layer (type)	Output Shape	Param #
input_layer (InputLayer)	(None, 32, 32, 1)	0
conv2d (Conv2D)	(None, 32, 32, 16)	160
max_pooling2d (MaxPooling2D)	(None, 16, 16, 16)	0
conv2d_1 (Conv2D)	(None, 16, 16, 8)	1,160
max_pooling2d_1 (MaxPooling2D)	(None, 8, 8, 8)	0
conv2d_2 (Conv2D)	(None, 8, 8, 8)	584
max_pooling2d_2 (MaxPooling2D)	(None, 4, 4, 8)	0
conv2d_transpose (Conv2DTranspose)	(None, 8, 8, 8)	584
conv2d_transpose_1 (Conv2DTranspose)	(None, 16, 16, 8)	584
conv2d_transpose_2 (Conv2DTranspose)	(None, 32, 32, 16)	1,168
conv2d_3 (Conv2D)	(None, 32, 32, 1)	145

Total params: 4,385 (17.13 KB)



Modelos

Modelo	# parámetros	MSE	MAE
A01-Dense	50992	0.009	0.032
A02-Dense	222384	0.006	0.025
A03-Conv-UpSampl	4385	0.009	0.033
A04-Conv-Transp	4385	0.005	0.025

¿por qué los modelos que usan capas convolucionales tienen menos parámetros que los que usan capas densas?

Imágenes con ruido

```
(x_train, _), (x_test, _) = mnist.load_data()

x_train = x_train.astype('float32') / 255.
x_test = x_test.astype('float32') / 255.

x_train = np.reshape(x_train, (len(x_train), 28, 28, 1))
x_test = np.reshape(x_test, (len(x_test), 28, 28, 1))

noise_factor = 0.5
x_train_noisy = x_train + noise_factor * np.random.normal(loc=0.0, scale=1.0,
                                                         size=x_train.shape)
x_test_noisy = x_test + noise_factor * np.random.normal(loc=0.0, scale=1.0,
                                                         size=x_test.shape)

x_train_noisy = np.clip(x_train_noisy, 0., 1.)
x_test_noisy = np.clip(x_test_noisy, 0., 1.)
```



Modelo convolucional usado

```
input_img = layers.Input(shape=(28, 28, 1))
x = layers.Conv2D(32, (3, 3), activation='relu', padding='same')(input_img)
x = layers.MaxPooling2D((2, 2), padding='same')(x)
x = layers.Conv2D(32, (3, 3), activation='relu', padding='same')(x)
encoded = layers.MaxPooling2D((2, 2), padding='same')(x)

# En este punto la representación es de (7, 7, 32)
x = layers.Conv2D(32, (3, 3), activation='relu', padding='same')(encoded)
x = layers.UpSampling2D((2, 2))(x)
x = layers.Conv2D(32, (3, 3), activation='relu', padding='same')(x)
x = layers.UpSampling2D((2, 2))(x)
decoded = layers.Conv2D(1, (3, 3), activation='sigmoid', padding='same')(x)


autoencoder = Model(input_img, decoded)
print(autoencoder.summary())
```

Resultado de la decodificación

```
autoencoder.fit(x_train_noisy, x_train, epochs=100, batch_size=128,  
                shuffle=True, validation_data=(x_test_noisy, x_test))
```

Predicción del Autoencoder para las imágenes de testeo

```
decoded_imgs = autoencoder.predict(x_test_noisy)
```



Detección de fraudes


- El conjunto de datos contiene transacciones realizadas por tarjetas de crédito en septiembre de 2013 por titulares de tarjetas europeas.
- Este conjunto de datos presenta las transacciones que se produjeron en dos días, donde tenemos 492 fraudes de 284.807 transacciones.
- El conjunto de datos es muy desequilibrado, la clase positiva (fraudes) representa el 0,172% de todas las transacciones

▣ [Link al dataset](#)

Autoencoder_detecta_fraude.ipynb


Variational autoencoders (VAE)

- En lugar de mapear cada imagen a un punto fijo, mapea a una distribución gaussiana centrada en $\mathbf{z}_{mean}$ con varianza $\mathbf{z}_{var}$



Espacio latente

- Se busca que siga una distribución $\mathcal{N}(0,1)$ para que sea **suave, continuo y generativo**; de esta forma:
 - ▣ Las representaciones de las entradas quedan **centradas alrededor del origen**.
 - ▣ Las diferentes clases (dígitos) se **organizan suavemente** en torno a una distribución común.
 - ▣ Cualquier punto tomado de una $\mathcal{N}(0,1)$ tendrá **sentido semántico** cuando se decodifique.
- Por eso, al final del entrenamiento, es posible:
 - ▣ Tomar **cualquier punto aleatorio** $z \sim \mathcal{N}(0,1)$ y el decoder generará una imagen válida.
 - ▣ Interpolar entre dos puntos z_1 y z_2 obteniendo **transiciones suaves** entre clases.



Variational autoencoders (VAE)



Variational-encoder.ipynb

Variational autoencoders (VAE)



Un espacio continuo de caras generadas por Tom White usando VAEs
(Figura 12.14 del libro de Chollet)